Mecânica dos Fluidos Computacional Métodos de Diferenças Finitas para Problemas Bidimensionais

lury Igreja

Programa de Pós-Graduação em Modelagem Computacional Departamento de Ciência da Computação Universidade Federal de Juiz de Fora iuryigreja@ice.ufjf.br

Conteúdo

- ▶ Problema Modelo Difusão
 - Discretização
 - ► Metodologia de Resolução
 - Validação Numérica
- ► Problema Modelo Difusão-Convecção
 - Discretização Upwind
 - Discretização Esquema Central
 - Resultados Numéricos
- ► Problema Modelo Difusão Transiente
 - Discretização
 - Comentários
 - ► Método ADI
 - ► Testes Numéricos
- ► Problema Modelo Difusão-Convecção Transiente
 - ► Método ADI Esquema Upwind
 - Método ADI Esquema Central
 - Resultados Numéricos

Problema Modelo - Difusão

Seja o domínio espacial $\Omega \subset \mathbb{R}^2$ com contorno $\partial \Omega$, dada as funções $f(x,y):\Omega \to \mathbb{R}$, $\overline{u}(x,y):\partial \Omega \to \mathbb{R}$ e g(x,y), encontrar $u(x,y):\Omega \to \mathbb{R}$, tal que:

$$-\Delta u(x,y) = -\left(\frac{\partial^2 u}{\partial x^2} + \frac{\partial^2 u}{\partial y^2}\right) = f(x,y) \quad \text{em} \quad \Omega$$

suplementado por condições de contorno do tipo Dirichlet

$$u(x,y) = \overline{u}(x,y)$$
 sobre $\partial \Omega_D$

ou Neumann

$$\nabla u(x,y) \cdot \mathbf{n} = g(x,y)$$
 sobre $\partial \Omega_N$

onde ${\bf n}$ é o vetor unitário normal com orientação exterior a $\partial\Omega_N$.

Discretização

Seja u(x,y) e o domínio $\Omega=[a_x,b_x]\times[a_y,b_y]$ onde $x\in[a_x,b_x]$ e $y\in[a_y,b_y]$. Neste domínio definimos discretizações uniformes nas direções x e y, como segue

$$y_j = y_0 + j\Delta y, \quad j = 0, 1, ..., J, \text{ com } \Delta y = \frac{b_y - a_y}{J - 1}$$

Neste contexto, definimos a seguinte discretização por diferença central para as derivadas de segunda ordem nas direções x e y:

$$\Delta u = \frac{\partial^2 u}{\partial x^2} + \frac{\partial^2 u}{\partial y^2} \approx \frac{u_{i-1,j} - 2u_{i,j} + u_{i+1,j}}{\Delta x^2} + \frac{u_{i,j-1} - 2u_{i,j} + u_{i,j+1}}{\Delta y^2}$$

Discretização

Escolhendo $\Delta x = \Delta y = h$, temos que

$$\Delta u \approx \frac{u_{i-1,j} - 2u_{i,j} + u_{i+1,j}}{h^2} + \frac{u_{i,j-1} - 2u_{i,j} + u_{i,j+1}}{h^2}$$

Logo podemos enunciar o seguinte problema discreto para difusão em 2 dimensões:

Encontrar $u_{i,j}$, com i = 1, 2, ..., I - 1 e j = 1, 2, ..., J - 1, satisfazendo:

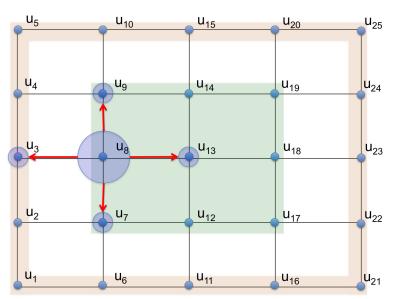
$$-\left(\frac{u_{i-1,j} + u_{i,j-1} - 4u_{i,j} + u_{i+1,j} + u_{i,j+1}}{h^2}\right) = f(x_i, y_j)$$

com condição de contorno

$$u_{0,j} = u_{i,0} = u_{I,j} = u_{i,J} = \overline{u}$$

Metodologia de Resolução

Supondo 4×4 elementos, ou seja, I=J=5, temos:



$$\mathbf{i}=\mathbf{1}$$
 e $\mathbf{j}=\mathbf{1}$

$$-\left(\frac{u_{i-1,j} + u_{i,j-1} - 4u_{i,j} + u_{i+1,j} + u_{i,j+1}}{h^2}\right) = f_{i,j}$$

$$-\left(\frac{u_{0,1}+u_{1,0}-4u_{1,1}+u_{2,1}+u_{1,2}}{h^2}\right)=f_{1,1}$$

$$-\left(\frac{-4u_{1,1}+u_{2,1}+u_{1,2}}{h^2}\right) = f(x_1, y_1) + \frac{u_{0,1}+u_{1,0}}{h^2}$$

$$\mathbf{i}=\mathbf{2}$$
 e $\mathbf{j}=\mathbf{1}$

$$-\left(\frac{u_{i-1,j} + u_{i,j-1} - 4u_{i,j} + u_{i+1,j} + u_{i,j+1}}{h^2}\right) = f_{i,j}$$

$$-\left(\frac{u_{1,1} + u_{2,0} - 4u_{2,1} + u_{3,1} + u_{2,2}}{h^2}\right) = f_{2,1}$$

$$-\left(\frac{u_{1,1} - 4u_{2,1} + u_{3,1} + u_{2,2}}{h^2}\right) = f(x_2, y_1) + \frac{u_{2,0}}{h^2}$$

$$\mathbf{i}=\mathbf{3}$$
 e $\mathbf{j}=\mathbf{1}$

$$-\left(\frac{u_{i-1,j} + u_{i,j-1} - 4u_{i,j} + u_{i+1,j} + u_{i,j+1}}{h^2}\right) = f_{i,j}$$

$$-\left(\frac{u_{2,1}+u_{3,0}-4u_{3,1}+u_{4,1}+u_{3,2}}{h^2}\right)=f_{3,1}$$

$$-\left(\frac{u_{2,1} - 4u_{3,1} + u_{3,2}}{h^2}\right) = f(x_3, y_1) + \frac{u_{2,0} + u_{4,1}}{h^2}$$

$$\mathbf{i}=\mathbf{1}$$
 e $\mathbf{j}=\mathbf{2}$

$$-\left(\frac{u_{i-1,j} + u_{i,j-1} - 4u_{i,j} + u_{i+1,j} + u_{i,j+1}}{h^2}\right) = f_{i,j}$$

$$-\left(\frac{u_{0,2}+u_{1,1}-4u_{1,2}+u_{2,2}+u_{1,3}}{h^2}\right)=f_{1,2}$$

$$-\left(\frac{u_{1,1} - 4u_{1,2} + u_{2,2} + u_{1,3}}{h^2}\right) = f(x_1, y_2) + \frac{u_{0,2}}{h^2}$$

$$\mathbf{i}=\mathbf{2}$$
 e $\mathbf{j}=\mathbf{2}$

$$-\left(\frac{u_{i-1,j}+u_{i,j-1}-4u_{i,j}+u_{i+1,j}+u_{i,j+1}}{h^2}\right)=f_{i,j}$$
 logo
$$-\left(\frac{u_{1,2}+u_{2,1}-4u_{2,2}+u_{3,2}+u_{2,3}}{h^2}\right)=f_{2,2}$$

$$\mathbf{i}=\mathbf{3}$$
 e $\mathbf{j}=\mathbf{2}$

$$-\left(\frac{u_{i-1,j} + u_{i,j-1} - 4u_{i,j} + u_{i+1,j} + u_{i,j+1}}{h^2}\right) = f_{i,j}$$

$$-\left(\frac{u_{2,2}+u_{3,1}-4u_{3,2}+u_{4,2}+u_{3,3}}{h^2}\right)=f_{3,2}$$

$$-\left(\frac{u_{2,2} + u_{3,1} - 4u_{3,2} + u_{3,3}}{h^2}\right) = f_{3,2} + \frac{u_{4,2}}{h^2}$$

$$\mathbf{i}=\mathbf{1}$$
 e $\mathbf{j}=\mathbf{3}$

$$-\left(\frac{u_{i-1,j} + u_{i,j-1} - 4u_{i,j} + u_{i+1,j} + u_{i,j+1}}{h^2}\right) = f_{i,j}$$

$$-\left(\frac{u_{0,3} + u_{1,2} - 4u_{1,3} + u_{2,3} + u_{1,4}}{h^2}\right) = f_{1,3}$$

$$-\left(\frac{u_{1,2} - 4u_{1,3} + u_{2,3}}{h^2}\right) = f_{1,3} + \frac{u_{0,3} + u_{1,4}}{h^2}$$

$$\mathbf{i}=\mathbf{2}$$
 e $\mathbf{j}=\mathbf{3}$

$$-\left(\frac{u_{i-1,j} + u_{i,j-1} - 4u_{i,j} + u_{i+1,j} + u_{i,j+1}}{h^2}\right) = f_{i,j}$$

$$-\left(\frac{u_{1,3} + u_{2,2} - 4u_{2,3} + u_{3,3} + u_{2,4}}{h^2}\right) = f_{2,3}$$

$$i=3$$
 e $i=3$

$$-\left(\frac{u_{i-1,j} + u_{i,j-1} - 4u_{i,j} + u_{i+1,j} + u_{i,j+1}}{h^2}\right) = f_{i,j}$$

$$-\left(\frac{u_{2,3} + u_{3,2} - 4u_{3,3} + u_{4,3} + u_{3,4}}{h^2}\right) = f_{3,3}$$

$$-\left(\frac{u_{2,3} + u_{3,2} - 4u_{3,3}}{h^2}\right) = f_{3,3} + \frac{u_{4,3} + u_{3,4}}{h^2}$$

Caso Geral

Dado um problema com $K\times K$ elementos, temos que a matriz gerada é da ordem de $(K-1)^2$, ou seja, é uma matriz quadrada $(K-1)^2\times (K-1)^2$, que pode ser generalizada como segue

$$\frac{1}{h^2} \begin{bmatrix} T & I & & & & & \\ I & T & I & & & & \\ & I & T & I & & & \\ & & \ddots & \ddots & \ddots & \\ & & & I & T & I \\ & & & & I & T \end{bmatrix}, T = \begin{bmatrix} -4 & 1 & & & & \\ 1 & -4 & 1 & & & \\ & 1 & -4 & 1 & & \\ & & \ddots & \ddots & \ddots & \\ & & & 1 & -4 & 1 \\ & & & & 1 & -4 \end{bmatrix}$$

onde I é a matriz identidade.

Para resolver pode-se empregar a decomposição LU que necessita de aproximadamente $\frac{2}{3}k^3$ operações, onde k é a dimensão da matriz.

Exemplo: Dada uma malha de 64×64 elementos, a matriz gerada é da ordem de $k=(K-1)^2=(64-1)^2=3969$. Assim, aplicando a decomposição LU, necessitamos de

$$\frac{2}{3}k^3 = \frac{2}{3}3969^3 = 41.682.334.806 \text{ operações}.$$

Validação Numérica

Encontrar u(x,y) satisfazendo a seguinte equação:

$$-\Delta u(x,y) = 2\pi^2 \sin(\pi x) \sin(\pi y) \quad \text{em} \quad \Omega$$

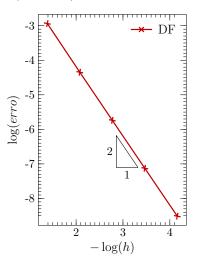
$$u(x,y) = \overline{u}, \qquad \text{sobre} \quad \partial \Omega$$

onde \overline{u} é definido pela solução exata

$$u(x,y) = \sin(\pi x)\sin(\pi y).$$

Estudo de Convergência

Para este estudo foram adotadas malhas de $4\times4, 8\times8, 16\times16, 32\times32, 64\times64$ elementos.



Problema Modelo - Difusão-Conveção

Seja o domínio espacial $\Omega \subset \mathbb{R}^2$ com contorno $\partial \Omega$, dado $\varepsilon > 0$ e as funções $f(x,y):\Omega \to \mathbb{R}$ e $\overline{u}(x,y):\partial \Omega \to \mathbb{R}$ e o vetor $\mathbf{b}=(b_1,b_2)$, encontrar $u(x,y):\Omega \to \mathbb{R}$, tal que:

$$-\varepsilon \Delta u(x,y) + \mathbf{b} \cdot \nabla u(x,y) = f(x,y)$$
 em Ω

ou ainda

$$-\varepsilon \left(\frac{\partial^2 u}{\partial x^2} + \frac{\partial^2 u}{\partial y^2} \right) + b_1 \frac{\partial u}{\partial x} + b_2 \frac{\partial u}{\partial y} = f(x, y)$$

suplementado por condições de contorno do tipo Dirichlet

$$u(x,y) = \overline{u}(x,y)$$
 sobre $\partial \Omega$

Discretização Upwind

Adotando discretização central para a difusão

$$\Delta u = \frac{\partial^2 u}{\partial x^2} + \frac{\partial^2 u}{\partial y^2} \approx \frac{u_{i-1,j} - 2u_{i,j} + u_{i+1,j}}{\Delta x^2} + \frac{u_{i,j-1} - 2u_{i,j} + u_{i,j+1}}{\Delta y^2}$$

е

$$\mathbf{b} \cdot \nabla u = b_1 \frac{\partial u}{\partial x} + b_2 \frac{\partial u}{\partial y}$$

$$\approx \begin{cases} b_1 \frac{u_{i,j} - u_{i-1,j}}{\Delta x} + b_2 \frac{u_{i,j} - u_{i,j-1}}{\Delta y}, & b_1, b_2 > 0 \\ b_1 \frac{u_{i+1,j} - u_{i,j}}{\Delta x} + b_2 \frac{u_{i,j+1} - u_{i,j}}{\Delta y}, & b_1, b_2 < 0 \end{cases}$$

para o termo convectivo.

Discretização Upwind

Adotando $\Delta x = \Delta y = h$ e supondo $b_1, b_2 > 0$, temos:

$$\frac{u_{i-1,j} - 2u_{i,j} + u_{i+1,j}}{h^2} + \frac{u_{i,j-1} - 2u_{i,j} + u_{i,j+1}}{h^2} + b_1 \frac{u_{i,j} - u_{i-1,j}}{h} + b_2 \frac{u_{i,j} - u_{i,j-1}}{h} = f(x_i, y_j)$$

Logo uma discretização para o problema modelo é dada por:

Encontrar $u_{i,j}$, com i = 1, 2, ..., I - 1 e j = 1, 2, ..., J - 1, satisfazendo:

$$-\varepsilon \left(\frac{u_{i-1,j} + u_{i,j-1} - 4u_{i,j} + u_{i+1,j} + u_{i,j+1}}{h^2}\right) + b_1 \frac{u_{i,j} - u_{i-1,j}}{h} + b_2 \frac{u_{i,j} - u_{i,j-1}}{h} = f(x_i, y_j)$$

Agrupando os termos, podemos reescrever como:

$$-\frac{1}{h^2} \left[(\varepsilon + b_1 h) u_{i-1,j} + (\varepsilon + b_2 h) u_{i,j-1} \right]$$
$$- (4\varepsilon + b_1 h + b_2 h) u_{i,j} + \varepsilon u_{i+1,j} + \varepsilon u_{i,j+1} = f(x_i, y_j)$$

Discretização Esquema Central

Adotando discretização central para a difusão

$$\Delta u = \frac{\partial^2 u}{\partial x^2} + \frac{\partial^2 u}{\partial y^2} \approx \frac{u_{i-1,j} - 2u_{i,j} + u_{i+1,j}}{\Delta x^2} + \frac{u_{i,j-1} - 2u_{i,j} + u_{i,j+1}}{\Delta y^2}$$

e central para a convecção

$$\mathbf{b} \cdot \nabla u = b_1 \frac{\partial u}{\partial x} + b_2 \frac{\partial u}{\partial y} \approx b_1 \frac{u_{i+1,j} - u_{i-1,j}}{2\Delta x} + b_2 \frac{u_{i,j+1} - u_{i,j-1}}{2\Delta y}$$

geramos a seguinte aproximação de segunda ordem:

Encontrar $u_{i,j}$, com i = 1, 2, ..., I - 1 e j = 1, 2, ..., J - 1, satisfazendo:

$$-\varepsilon \left(\frac{u_{i-1,j} - 2u_{i,j} + u_{i+1,j}}{\Delta x^2} + \frac{u_{i,j-1} - 2u_{i,j} + u_{i,j+1}}{\Delta y^2} \right) + b_1 \frac{u_{i+1,j} - u_{i-1,j}}{2\Delta x} + b_2 \frac{u_{i,j+1} - u_{i,j-1}}{2\Delta y} = f(x_i, y_j)$$

Discretização Esquema Central

Adotando $\Delta x = \Delta y = h$, obtemos:

$$-\varepsilon \left(\frac{u_{i-1,j} - 2u_{i,j} + u_{i+1,j}}{h^2} + \frac{u_{i,j-1} - 2u_{i,j} + u_{i,j+1}}{h^2} \right) + b_1 \frac{u_{i+1,j} - u_{i-1,j}}{2h} + b_2 \frac{u_{i,j+1} - u_{i,j-1}}{2h} = f(x_i, y_j)$$

Logo, temos que

$$-\varepsilon \left(\frac{u_{i-1,j} + u_{i,j-1} - 4u_{i,j} + u_{i+1,j} + u_{i,j+1}}{h^2} \right) + b_1 \frac{u_{i+1,j} - u_{i-1,j}}{2h} + b_2 \frac{u_{i,j+1} - u_{i,j-1}}{2h} = f(x_i, y_j)$$

Agrupando os termos, podemos reescrever como:

$$-\frac{1}{h^2} \left[(\varepsilon + b_1 h/2) u_{i-1,j} + (\varepsilon + b_2 h/2) u_{i,j-1} - 4\varepsilon u_{i,j} + (\varepsilon - b_1 h/2) u_{i+1,j} + (\varepsilon - b_2 h/2) u_{i,j+1} \right] = f(x_i, y_j)$$

Resultados Numéricos

Encontrar u(x,y) satisfazendo a seguinte equação:

$$-\varepsilon\Delta u(x,y) + \mathbf{b}\cdot\nabla u(x,y) = f(x,y) \quad \text{em} \quad \Omega$$

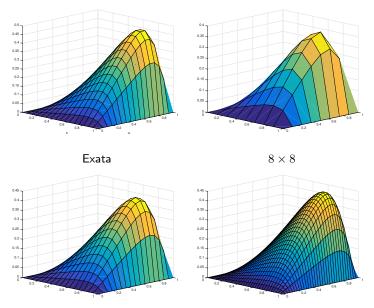
$$u(x,y) = \overline{u} \quad \text{sobre} \quad \partial\Omega$$

onde $\overline{u}(x,y)$ e f(x,y) são derivados da seguinte solução exata

$$u(x,y) = xy \frac{(1 - e^{(x-1)b_1})(1 - e^{(y-1)b_2})}{(1 - e^{-b_1})(1 - e^{-b_2})}$$

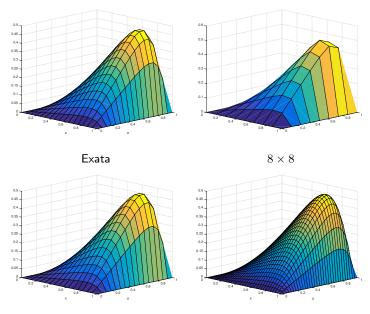
onde $\mathbf{b}=(b_1,b_2)$, $\varepsilon=1$ e o domínio $\Omega=[0,1]\times[0,1].$

Upwind – b = (10, 10)



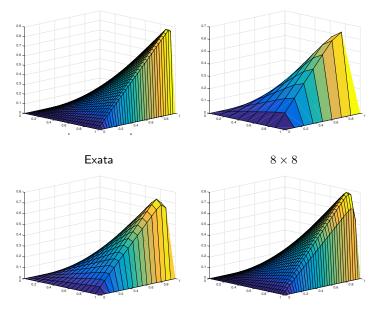
 16×16 32×32 25/53

Esquema Central – $\mathbf{b} = (10, 10)$



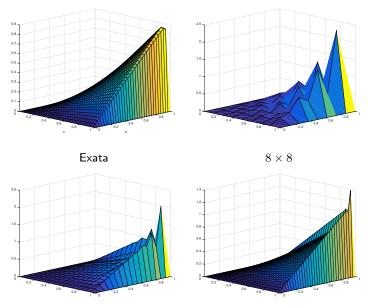
 16×16 32×32 26/53

Upwind – $\mathbf{b} = (100, 100)$



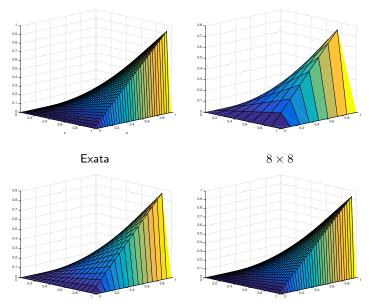
 16×16 32×32 27/53

Esquema Central – $\mathbf{b} = (100, 100)$



 16×16 32×32 28/53

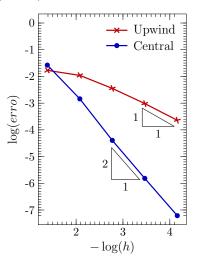
$\mathsf{Upwind} - \mathbf{b} = (10^6, 10^6)$



 $16\times16 \hspace{1.5cm} 32\times32 \hspace{1.5cm} 29\,/\,\mathrm{53}$

Estudo de Convergência

Para este estudo foi adotado $4\times4, 8\times8, 16\times16, 32\times32, 64\times64$ elementos e $\mathbf{b}=(10,10).$



Problema Modelo - Difusão Transiente

Seja o domínio espacial $\Omega \subset \mathbb{R}^d$ com contorno $\partial \Omega$ e o domínio temporal $\Theta = [0,T]$, dada as funções $f(\mathbf{x},t): \Omega \times \Theta \to \mathbb{R}$, $\overline{u}(\mathbf{x},t): \partial \Omega \times \Theta \to \mathbb{R}$, $\varphi(\mathbf{x}): \Omega \to \mathbb{R}$ e $\varepsilon > 0$, encontrar $u(\mathbf{x},t): \Omega \times \Theta \to \mathbb{R}$, tal que:

$$\frac{\partial u}{\partial t} - \varepsilon \Delta u = f(\mathbf{x}, t), \quad (\mathbf{x}, t) \in \Omega \times \Theta$$

suplementado por condições de Dirichlet

$$u(\mathbf{x},t) = \overline{u}(\mathbf{x},t),$$

e a condição inicial

$$u(\mathbf{x},0) = \varphi(\mathbf{x}).$$

onde
$$\mathbf{x} = (x, y)$$

Discretização

Definindo $\Delta t = T/(N-1)$ e $t_n = n\Delta t$, com n=0,1,2,...,N, onde N é um inteiro positivo. Para o termo da derivada segunda no espaço adotamos um esquema de diferença central, com $\Delta x = \Delta y = h$,

$$\frac{u_{i,j}^{n+1} - u_{i,j}^n}{\Delta t} - \varepsilon \left(\frac{u_{i-1,j}^{n+1} + u_{i,j-1}^{n+1} - 4u_{i,j}^{n+1} + u_{i+1,j}^{n+1} + u_{i,j+1}^{n+1}}{h^2} \right)$$
$$= f(x_i, y_j, t_n + \Delta t),$$

ordem de convergência $\mathcal{O}(h^2, \Delta t)$

Comentários

- Matriz gerada seguindo os mesmos passos apresentados anteriormente incluindo o termo temporal no passo de tempo n+1.
- ightharpoonup O termo fonte inclui a solução no passo de tempo n.
- O custo computacional aplicando a estratégia de decomposição LU para resolver o sistema é da ordem de $\frac{2}{3}k^3n$, onde k é a dimensão da matriz e n o número de passos temporais

Exemplo: Já vimos que para uma malha de 64×64 elementos, aplicando a decomposição LU, necessitamos de $\frac{2}{3}k^3 = \frac{2}{3}3969^3 = 41.682.334.806$ operações. Se for necessário n=1000 iterações no tempo, esse número de operações aumenta mil vezes.

Método ADI

Uma alternativa para reduzir o custo computacional é o método implícito de direções alternadas ADI¹ (*Alternating Direction Implicit*). Esta metodologia é feita em dois passos, como segue:

• Primeiro Passo: (Implícito em x)

$$\frac{\hat{u}_{i,j}^{n+1/2} - u_{i,j}^n}{\Delta t/2} = \varepsilon \left[\frac{\hat{u}_{i+1,j}^{n+1/2} - 2\hat{u}_{i,j}^{n+1/2} + \hat{u}_{i-1,j}^{n+1/2}}{\Delta x^2} + \frac{u_{i,j+1}^n - 2u_{i,j}^n + u_{i,j-1}^n}{\Delta y^2} \right]$$

• **Segundo Passo**: (Implícito em *y*)

$$\frac{u_{i,j}^{n+1} - \hat{u}_{i,j}^{n+1/2}}{\Delta t/2} = \varepsilon \left[\frac{\hat{u}_{i+1,j}^{n+1/2} - 2\hat{u}_{i,j}^{n+1/2} + \hat{u}_{i-1,j}^{n+1/2}}{\Delta x^2} + \frac{u_{i,j+1}^{n+1} - 2u_{i,j}^{n+1} + u_{i,j-1}^{n+1}}{\Delta y^2} \right]$$

- Método incondicionalmente estável por von Neumann
- ▶ Ordem de convergência $\mathcal{O}(h^2, \Delta t^2)$
- ► Solução de matrizes tridiagonais em cada passo.

¹D. W. Peaceman and H. H. Rachford, Jr., The Numerical Solution of Parabolic and Elliptic Differential Equations. J Soc. Indust. Appl. Math., 3(1), 28–41. https://doi.org/10.1137/0103003

Método ADI

Escolhendo $\Delta x = \Delta y = h$, podemos reescrever a discretização da seguinte forma:

$$(1+\sigma)\hat{u}_{i,j}^{n+1/2} - \frac{\sigma}{2}\left(\hat{u}_{i+1,j}^{n+1/2} + \hat{u}_{i-1,j}^{n+1/2}\right) = (1-\sigma)u_{i,j}^{n} + \frac{\sigma}{2}\left(u_{i,j+1}^{n} + u_{i,j-1}^{n}\right)$$

$$(1+\sigma)u_{i,j}^{n+1} - \frac{\sigma}{2}\left(u_{i,j+1}^{n+1} + u_{i,j-1}^{n+1}\right) = (1-\sigma)\hat{u}_{i,j}^{n+1/2} + \frac{\sigma}{2}\left(\hat{u}_{i+1,j}^{n+1/2} + \hat{u}_{i-1,j}^{n+1/2}\right)$$

- Primeiro passo: resolve a difusão na direção x com a condição inicial. Neste passo, a difusão em x é incógnita e a difusão em y conhecida.
- Segundo passo: resolve a difusão na direção y, que agora é incógnita, utilizando a solução do primeiro passo para difusão em x, que entra na segunda expressão de forma conhecida.

Método ADI - First step

Supondo uma malha de 4×4 elementos, primeiramente resolvemos a difusão em x implícita e em y explícita para cada plano x. Assim:

▶ Para n = 0, i = 1 e j = 1

$$(1+\sigma)\hat{u}_{1,1}^{1/2} - \frac{\sigma}{2}\left(\hat{u}_{2,1}^{1/2} + \hat{u}_{0,1}^{1/2}\right) = (1-\sigma)u_{1,1}^0 + \frac{\sigma}{2}\left(u_{1,2}^0 + u_{1,0}^0\right)$$

$$\begin{bmatrix} (1+\sigma) & -\sigma/2 & 0 \\ \times & \times & \times \\ \times & \times & \times \end{bmatrix} \begin{bmatrix} \hat{u}_{1,1}^{1/2} \\ \hat{u}_{2,1}^{1/2} \\ \hat{u}_{3,1}^{1/2} \end{bmatrix} = \begin{bmatrix} (1-\sigma)u_{1,1}^0 + \frac{\sigma}{2}(u_{1,2}^0 + u_{1,0}^0 + \hat{u}_{0,1}^{1/2}) \\ \times & \times \end{bmatrix}$$

Método ADI – First step

▶ Para
$$n = 0$$
, $i = 2$ e $j = 1$

$$(1+\sigma)\hat{u}_{2,1}^{1/2} - \frac{\sigma}{2} \left(\hat{u}_{3,1}^{1/2} + \hat{u}_{1,1}^{1/2} \right) = (1-\sigma)u_{2,1}^0 + \frac{\sigma}{2} \left(u_{2,2}^0 + u_{2,0}^0 \right)$$

$$\begin{bmatrix} (1+\sigma) & -\sigma/2 & 0 \\ -\sigma/2 & (1+\sigma) & -\sigma/2 \\ \times & \times & \times \end{bmatrix} \begin{bmatrix} \hat{u}_{1,1}^{1/2} \\ \hat{u}_{2,1}^{1/2} \\ \hat{u}_{3,1}^{1/2} \end{bmatrix} = \begin{bmatrix} (1-\sigma)u_{1,1}^{0} + \frac{\sigma}{2}(u_{1,2}^{0} + u_{1,0}^{0} + \hat{u}_{0,1}^{1/2}) \\ (1-\sigma)u_{2,1}^{0} + \frac{\sigma}{2}(u_{2,2}^{0} + u_{2,0}^{0}) \\ \times \end{bmatrix}$$

Método ADI - First step

▶ Para
$$n = 0$$
, $i = 3$ e $j = 1$

$$(1+\sigma)\hat{u}_{3,1}^{1/2} - \frac{\sigma}{2}\left(\hat{u}_{4,1}^{1/2} + \hat{u}_{2,1}^{1/2}\right) = (1-\sigma)u_{3,1}^{0} + \frac{\sigma}{2}\left(u_{3,2}^{0} + u_{3,0}^{0}\right)$$

$$\begin{bmatrix} (1+\sigma) & -\sigma/2 & 0 \\ -\sigma/2 & (1+\sigma) & -\sigma/2 \\ 0 & -\sigma/2 & (1+\sigma) \end{bmatrix} \begin{bmatrix} \hat{u}_{1,1}^{1/2} \\ \hat{u}_{2,1}^{1/2} \\ \hat{u}_{3,1}^{1/2} \end{bmatrix} = \begin{bmatrix} (1-\sigma)u_{1,1}^0 + \frac{\sigma}{2}(u_{1,2}^0 + u_{1,0}^0 + \hat{u}_{0,1}^{1/2}) \\ (1-\sigma)u_{2,1}^0 + \frac{\sigma}{2}(u_{2,2}^0 + u_{2,0}^0) \\ (1-\sigma)u_{3,1}^0 + \frac{\sigma}{2}(u_{3,2}^0 + u_{3,0}^0 + \hat{u}_{4,1}^{1/2}) \end{bmatrix}$$

Método ADI – First step

▶ Para
$$n = 0$$
, $i = 1$ e $j = 2$

$$(1+\sigma)\hat{u}_{1,2}^{1/2} - \frac{\sigma}{2}\left(\hat{u}_{2,2}^{1/2} + \hat{u}_{0,2}^{1/2}\right) = (1-\sigma)u_{1,2}^0 + \frac{\sigma}{2}\left(u_{1,3}^0 + u_{1,1}^0\right)$$

$$(1+\sigma)\hat{u}_{2,2}^{1/2} - \frac{\sigma}{2}\left(\hat{u}_{3,2}^{1/2} + \hat{u}_{1,2}^{1/2}\right) = (1-\sigma)u_{2,2}^0 + \frac{\sigma}{2}\left(u_{2,3}^0 + u_{2,1}^0\right)$$

▶ Para
$$n = 0$$
, $i = 3$ e $j = 2$

$$(1+\sigma)\hat{a}^{1/2} - \frac{\sigma}{\sigma} \left(\hat{a}^{1/2}\right)$$

$$(1+\sigma)\hat{y}_{0,2}^{1/2} - \frac{\sigma}{\sigma}(\hat{y}_{1,2}^{1/2} +$$

$$(1+\sigma)\hat{u}_{3,2}^{1/2} - \frac{\sigma}{2}\left(\hat{u}_{4,2}^{1/2} + \right)$$

$$(1+\sigma)\hat{u}_{3,2}^{1/2} - \frac{\sigma}{2}\left(\hat{u}_{4,2}^{1/2} + \hat{u}_{2,2}^{1/2}\right) = (1-\sigma)u_{3,2}^0 + \frac{\sigma}{2}\left(u_{3,3}^0 + u_{3,1}^0\right)$$

$$(1+\sigma)\hat{u}_{3,2}^{1/2} - \frac{1}{2}\left(\hat{u}_{4,2}^{1/2} + \frac{1}{2}\right)$$

$$a_{4,2} - \frac{1}{2} (u_{4,2} + u_{4,2})$$

$$(a_{2,2} + a_{2,2}) = (a_{2,2} + a_{2,2})$$

$$-\frac{\sigma}{2}(u_{1,3}^0+u_{1,1}^0+v_{1,1}^0)$$

$$\begin{bmatrix} (1+\sigma) & -\sigma/2 & 0 \\ -\sigma/2 & (1+\sigma) & -\sigma/2 \\ 0 & -\sigma/2 & (1+\sigma) \end{bmatrix} \begin{bmatrix} \hat{u}_{1,2}^{1/2} \\ \hat{u}_{2,2}^{1/2} \\ \hat{u}_{3,2}^{1/2} \end{bmatrix} = \begin{bmatrix} (1-\sigma)u_{1,2}^0 + \frac{\sigma}{2}(u_{1,3}^0 + u_{1,1}^0 + \hat{u}_{0,2}^{1/2}) \\ (1-\sigma)u_{2,2}^0 + \frac{\sigma}{2}(u_{2,3}^0 + u_{2,1}^0) \\ (1-\sigma)u_{3,2}^0 + \frac{\sigma}{2}(u_{3,3}^0 + u_{3,1}^0 + \hat{u}_{4,2}^{1/2}) \end{bmatrix}$$

Para
$$n = 0$$
 $i = 3$ e $i = 2$

$$i=2$$
 e $j=2$

$$\hat{u}_{2,2}^{1/2} + \hat{u}_0^1$$

$$0, i = 1 e j = 1$$

$$i = 0, i = 1$$
e $j = 1$

Le
$$i=2$$

39 / 53

Método ADI – First step

▶ Para
$$n = 0$$
, $i = 1$ e $j = 3$

$$(1+\sigma)\hat{u}_{1,3}^{1/2} - \frac{\sigma}{2}\left(\hat{u}_{2,3}^{1/2} + \hat{u}_{0,3}^{1/2}\right) = (1-\sigma)u_{1,3}^0 + \frac{\sigma}{2}\left(u_{1,4}^0 + u_{1,2}^0\right)$$

$$(1+o)u_{1,3} - \frac{1}{2}(u_{2,3} + o)$$
• Para $n = 0$, $i = 2$ e $j = 3$

$$(1+\sigma)\hat{u}_{2,3}^{1/2} - \frac{\sigma}{2}\left(\hat{u}_{3,3}^{1/2} + \hat{u}_{1,3}^{1/2}\right) = (1-\sigma)u_{2,3}^0 + \frac{\sigma}{2}\left(u_{2,4}^0 + u_{2,2}^0\right)$$

$$ightharpoonup$$
 Para $n=0$, $i=3$ e $j=1$

$$(1+\sigma)\hat{y}_{-1}^{1/2} - \frac{\sigma}{\sigma}(\hat{y}_{-1}^{1/2} +$$

$$(1+\sigma)\hat{u}_{3,3}^{1/2}-\frac{\sigma}{2}\left(\hat{u}_{4,3}^{1/2}+\right.$$

$$(1+\sigma)\hat{u}_{3,3}^{1/2}-rac{\sigma}{2}\left(\hat{u}_{4,3}^{1/2}+
ight.$$

$$(1+\sigma)\hat{u}_{3,3}^{1/2} - \frac{\sigma}{2}\left(\hat{u}_{4,3}^{1/2} + \hat{u}_{2,3}^{1/2}\right) = (1-\sigma)u_{3,3}^0 + \frac{\sigma}{2}\left(u_{3,4}^0 + u_{3,2}^0\right)$$

$$\hat{u}_{3,3}^{1/2} - \frac{\sigma}{2} \left(\hat{u}_{4,3}^{1/2} + \hat{u}_{4,3}^{1/2} \right)$$

$$+\hat{u}_{2,3}^{1/2}$$
) = $(1-\sigma)u_3^6$

$$\begin{bmatrix} (1+\sigma) & -\sigma/2 & 0 \\ -\sigma/2 & (1+\sigma) & -\sigma/2 \\ 0 & -\sigma/2 & (1+\sigma) \end{bmatrix} \begin{bmatrix} \hat{u}_{1,3}^{1/2} \\ \hat{u}_{2,3}^{1/2} \\ \hat{u}_{3,3}^{1/2} \end{bmatrix} = \begin{bmatrix} (1-\sigma)u_{1,3}^0 + \frac{\sigma}{2}(u_{1,4}^0 + u_{1,2}^0 + \hat{u}_{0,3}^{1/2}) \\ (1-\sigma)u_{2,3}^0 + \frac{\sigma}{2}(u_{2,4}^0 + u_{2,2}^0) \\ (1-\sigma)u_{3,3}^0 + \frac{\sigma}{2}(u_{3,4}^0 + u_{3,2}^0 + \hat{u}_{4,3}^{1/2}) \end{bmatrix}$$

▶ Para
$$n = 0$$
, $i = 3$ e $j = 3$

$$\left(\hat{u}_{4,3}^{1/2} + \hat{u}_{2,3}^{1/2}\right)$$

$$+ \hat{u}_{2,3}^{1/2} = (1 - \epsilon)$$

$$(1-\sigma)u_{3,3}^0 + \frac{\sigma}{2}$$

$$\sigma$$
 () ()

$$+u_{-1}^0$$

Método ADI – Second step

Na segunda etapa, a solução $\hat{u}_{i,j}^{n+1/2}$ do termo difusivo em x é usada para obter a solução da variável de interesse $u_{i,j}^{n+1}$ referente a componente difusiva y que é calculada implicitamente.

componente difusiva
$$y$$
 que é calculada implicitamente.
Para $n = 0$, $i = 1$ e $j = 1$
$$(1 + \sigma)u_{1,1}^1 - \frac{\sigma}{2}\left(u_{1,2}^1 + u_{1,0}^1\right) = (1 - \sigma)\hat{u}_{1,1}^{1/2} + \frac{\sigma}{2}\left(\hat{u}_{2,1}^{1/2} + \hat{u}_{0,1}^{1/2}\right)$$

Para
$$n = 0$$
, $i = 1$ e $j = 2$

$$(1 + \sigma)x^{1} \qquad \sigma \qquad (x^{1} + x^{1}) = (1 - \sigma)\hat{x}^{1/2} + \frac{\sigma}{2}(\hat{x}^{1/2})$$

$$(1+\sigma)u_{1,2}^{1} - \frac{\sigma}{2}\left(u_{1,3}^{1} + u_{1,1}^{1}\right) = (1-\sigma)\hat{u}_{1,2}^{1/2} + \frac{\sigma}{2}\left(\hat{u}_{2,2}^{1/2} + \hat{u}_{0,2}^{1/2}\right)$$

$$\blacktriangleright \text{ Para } n = 0, \ i = 1 \text{ e } j = 3$$

$$(1+\sigma)u_{1,2}^{1} - \frac{\sigma}{2}\left(u_{1,2}^{1} + u_{1,2}^{1}\right) = (1-\sigma)\hat{u}_{1,2}^{1/2} + \frac{\sigma}{2}\left(\hat{u}_{2,2}^{1/2} + \hat{u}_{0,2}^{1/2}\right)$$

 $\begin{bmatrix} (1+\sigma) & -\sigma/2 & 0 \\ -\sigma/2 & (1+\sigma) & -\sigma/2 \\ 0 & -\sigma/2 & (1+\sigma) \end{bmatrix} \begin{bmatrix} u_{1,1}^1 \\ u_{1,2}^1 \\ u_{1,3}^1 \end{bmatrix} = \begin{bmatrix} (1-\sigma)\hat{u}_{1,1}^{1/2} + \frac{\sigma}{2}(\hat{u}_{2,1}^{1/2} + \hat{u}_{0,1}^{1/2} + u_{1,0}^1) \\ (1-\sigma)\hat{u}_{1,2}^{1/2} + \frac{\sigma}{2}(\hat{u}_{2,2}^{1/2} + \hat{u}_{0,2}^{1/2}) \\ (1-\sigma)\hat{u}_{1,3}^{1/2} + \frac{\sigma}{2}(\hat{u}_{2,2}^{1/2} + \hat{u}_{0,3}^{1/2} + u_{1,4}^1) \end{bmatrix}$

Método ADI – Second step

$$\blacktriangleright \ \mathsf{Para} \ n=0, \ i=2 \ \mathsf{e} \ j=1$$

$$(1+\sigma)u_{2,1}^1 - \frac{\sigma}{2}(u_{2,2}^1 + u_{2,2}^1)$$

$$(1+\sigma)u_{2,1}^1 - \frac{\sigma}{2}\left(u_{2,2}^1 + \iota\right)$$

$$(1+\sigma)u_{2,1}^1 - \frac{3}{2}\left(u_{2,2}^1 + u_{2,2}^1\right)$$
Para $n = 0$, $i = 2$ e $j = 2$

$$(1+\sigma)u_{2,1}^1 - \frac{\sigma}{2}\left(u_{2,2}^1 + u_2^1\right)$$

▶ Para n = 0. i = 2 e i = 3

$$(1+\sigma)u_{2,1}^1 - \frac{\sigma}{2}\left(u_{2,2}^1 + u_2^1\right)$$

$$(1+\sigma)u_{2,1}^1 - \frac{\sigma}{2}\left(u_{2,2}^1 + u_{2,0}^1\right) = (1-\sigma)\hat{u}_{2,1}^{1/2} + \frac{\sigma}{2}\left(\hat{u}_{3,1}^{1/2} + \hat{u}_{1,1}^{1/2}\right)$$

$$(1+\sigma)u_{2,1}^1 - \frac{\sigma}{\sigma}(u_{2,2}^1 + u_{2,2}^1)$$

rara
$$n = 0$$
, $i = 2$ e $j = 1$

$$2 e j = 1$$

$$j = 1$$

$$j = 1$$

 $(1+\sigma)u_{2,2}^1 - \frac{\sigma}{2}\left(u_{2,3}^1 + u_{2,1}^1\right) = (1-\sigma)\hat{u}_{2,2}^{1/2} + \frac{\sigma}{2}\left(\hat{u}_{3,2}^{1/2} + \hat{u}_{1,2}^{1/2}\right)$

 $(1+\sigma)u_{2,3}^1 - \frac{\sigma}{2}\left(u_{2,4}^1 + u_{2,2}^1\right) = (1-\sigma)\hat{u}_{2,3}^{1/2} + \frac{\sigma}{2}\left(\hat{u}_{3,3}^{1/2} + \hat{u}_{1,3}^{1/2}\right)$

 $\begin{bmatrix} (1+\sigma) & -\sigma/2 & 0 \\ -\sigma/2 & (1+\sigma) & -\sigma/2 \\ 0 & -\sigma/2 & (1+\sigma) \end{bmatrix} \begin{bmatrix} u_{2,1}^1 \\ u_{2,2}^1 \\ u_{2,3}^1 \end{bmatrix} = \begin{bmatrix} (1-\sigma)\hat{u}_{2,1}^{1/2} + \frac{\sigma}{2}(\hat{u}_{3,1}^{1/2} + \hat{u}_{1,1}^{1/2} + u_{2,0}^1) \\ (1-\sigma)\hat{u}_{2,2}^{1/2} + \frac{\sigma}{2}(\hat{u}_{3,2}^{1/2} + \hat{u}_{1,2}^{1/2}) \\ (1-\sigma)\hat{u}_{2,3}^{1/2} + \frac{\sigma}{2}(\hat{u}_{3,2}^{1/2} + \hat{u}_{1,3}^{1/2} + u_{2,4}^1) \end{bmatrix}$



Método ADI – Second step

▶ Para
$$n = 0$$
, $i = 3$ e $j =$

$$(1+\sigma)u_{3,1}^1 - \frac{\sigma}{2}\left(u_{3,2}^1 + u_{3,2}^1\right)$$

$$(1+\sigma)u_{3,1}^1 - \frac{\sigma}{2} \left(u_{3,2}^1 + u_{3,2}^1 + u$$

$$(1+\sigma)u_{3,1}^{2} - \frac{1}{2}(u_{3,2}^{2} + u_{3,2}^{2})$$

$$(1+\sigma)u_{3,1}^1 - \frac{6}{2}\left(u_{3,2}^1 + u_3^1\right)$$

▶ Para n = 0. i = 3 e i = 3

$$(1+\sigma)u_{3,1}^1 - \frac{\sigma}{2}\left(u_{3,2}^1 + u_{3,0}^1\right) = (1-\sigma)\hat{u}_{3,1}^{1/2} + \frac{\sigma}{2}\left(\hat{u}_{4,1}^{1/2} + \hat{u}_{2,1}^{1/2}\right)$$

$$(1+\sigma)u_{3,1}^1-\frac{\sigma}{2}\left(u_{3,2}^1+u_{3,2}^1\right)$$

▶ Para n = 0, i = 3 e j = 1

 $(1+\sigma)u_{3,2}^1 - \frac{\sigma}{2}\left(u_{3,3}^1 + u_{3,1}^1\right) = (1-\sigma)\hat{u}_{3,2}^{1/2} + \frac{\sigma}{2}\left(\hat{u}_{4,2}^{1/2} + \hat{u}_{2,2}^{1/2}\right)$

 $(1+\sigma)u_{3,3}^1 - \frac{\sigma}{2}\left(u_{3,4}^1 + u_{3,2}^1\right) = (1-\sigma)\hat{u}_{3,3}^{1/2} + \frac{\sigma}{2}\left(\hat{u}_{4,3}^{1/2} + \hat{u}_{2,3}^{1/2}\right)$

 $\begin{bmatrix} (1+\sigma) & -\sigma/2 & 0 \\ -\sigma/2 & (1+\sigma) & -\sigma/2 \\ 0 & -\sigma/2 & (1+\sigma) \end{bmatrix} \begin{bmatrix} u_{3,1}^1 \\ u_{3,2}^1 \\ u_{3,3}^1 \end{bmatrix} = \begin{bmatrix} (1-\sigma)\hat{u}_{3,1}^{1/2} + \frac{\sigma}{2}(\hat{u}_{4,1}^{1/2} + \hat{u}_{2,1}^{1/2} + u_{3,0}^1) \\ (1-\sigma)\hat{u}_{3,2}^{1/2} + \frac{\sigma}{2}(\hat{u}_{4,2}^{1/2} + \hat{u}_{2,2}^{1/2}) \\ (1-\sigma)\hat{u}_{3,3}^{1/2} + \frac{\sigma}{2}(\hat{u}_{4,2}^{1/2} + \hat{u}_{2,2}^{1/2}) \\ (1-\sigma)\hat{u}_{3,3}^{1/2} + \frac{\sigma}{2}(\hat{u}_{4,2}^{1/2} + \hat{u}_{2,3}^{1/2} + u_{3,4}^1) \end{bmatrix}$

Testes Numéricos

$$\frac{\partial u}{\partial t} - \varepsilon \Delta u = 0 \quad \text{em} \quad \Omega \times \Theta$$

suplementado por condições de Dirichlet

$$u(x,y,t)=0$$
, sobre $\partial\Omega\times\Theta$

e a condição inicial

$$u(x, y, 0) = \varphi(x, y) = \sin(\pi x/2)\sin(\pi y/2).$$

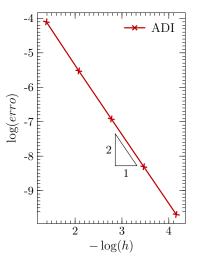
Uma solução exata para este problema é dada por:

$$u(x, y, t) = e^{-\pi^2 t/2} \sin(\pi x/2) \sin(\pi y/2)$$

no domínio espacial $\Omega = [0,2] \times [0,2]$ e temporal $\Theta = [0,0.5]$ com $\varepsilon = 1.0.$

Estudo de Convergência

Para este estudo foi adotado $4\times 4, 8\times 8, 16\times 16, 32\times 32, 64\times 64$ elementos e $\Delta t=h$.



Problema Modelo - Difusão-Convecção Transiente

Seja o domínio espacial $\Omega \subset \mathbb{R}^d$ com contorno $\partial\Omega$ e o domínio temporal $\Theta = [0,T]$, dada as funções $f(\mathbf{x},t): \Omega \times \Theta \to \mathbb{R}$, $\overline{u}(\mathbf{x},t): \partial\Omega \times \Theta \to \mathbb{R}$, $\varphi(\mathbf{x}): \Omega \to \mathbb{R}$, $\varepsilon > 0$ e $\mathbf{b} = (b_1,b_2)$, encontrar $u(\mathbf{x},t): \Omega \times \Theta \to \mathbb{R}$, tal que:

$$\frac{\partial u}{\partial t} - \varepsilon \Delta u + \mathbf{b} \cdot \nabla u = f(\mathbf{x}, t), \quad (\mathbf{x}, t) \in \Omega \times \Theta$$

suplementado por condições de Dirichlet

$$u(\mathbf{x},t) = \overline{u}(\mathbf{x},t),$$

e a condição inicial

$$u(\mathbf{x}, 0) = \varphi(\mathbf{x}),$$

onde $\mathbf{x} = (x, y)$.

Método ADI - Esquema Upwind

Combinando a estratégia ADI com uma discretização upwind para o termo convectivo, obtemos:

$$\frac{\hat{u}_{i,j}^{n+1/2} - u_{i,j}^{n}}{\Delta t/2} = \varepsilon \left[\frac{\hat{u}_{i+1,j}^{n+1/2} - 2\hat{u}_{i,j}^{n+1/2} + \hat{u}_{i-1,j}^{n+1/2}}{\Delta x^{2}} + \frac{u_{i,j+1}^{n} - 2u_{i,j}^{n} + u_{i,j-1}^{n}}{\Delta y^{2}} \right] - \begin{cases} b1 \frac{\hat{u}_{i,j}^{n+1/2} - \hat{u}_{i-1,j}^{n+1/2}}{\Delta x} + b2 \frac{u_{i,j}^{n} - u_{i,j-1}^{n}}{\Delta y} & b_{1}, b_{2} > 0 \\ b1 \frac{\hat{u}_{i+1,j}^{n+1/2} - \hat{u}_{i,j}^{n+1/2}}{\Delta x} + b2 \frac{u_{i,j+1}^{n} - u_{i,j}^{n}}{\Delta y} & b_{1}, b_{2} < 0 \end{cases}$$

$$\frac{u_{i,j}^{n+1} - \hat{u}_{i,j}^{n+1/2}}{\Delta t/2} = \varepsilon \left[\frac{\hat{u}_{i+1,j}^{n+1/2} - 2\hat{u}_{i,j}^{n+1/2} + \hat{u}_{i-1,j}^{n+1/2}}{\Delta x^2} + \frac{u_{i,j+1}^{n+1} - 2u_{i,j}^{n+1} + u_{i,j-1}^{n+1}}{\Delta y^2} \right]$$

$$- \begin{cases} b1 \frac{\hat{u}_{i,j}^{n+1/2} - \hat{u}_{i-1,j}^{n+1/2}}{\Delta x} + b_2 \frac{u_{i,j}^{n+1} - u_{i,j-1}^{n+1}}{\Delta y} & b_1, b_2 > 0 \\ b1 \frac{\hat{u}_{i+1,j}^{n+1/2} - \hat{u}_{i,j}^{n+1/2}}{\Delta x} + b_2 \frac{u_{i,j+1}^{n+1} - u_{i,j}^{n+1}}{\Delta y} & b_1, b_2 < 0 \end{cases}$$

Método ADI – Esquema Upwind

Escolhendo $\Delta x = \Delta y = h$ e supondo $b_1, b_2 > 0$, podemos reescrever a discretização da seguinte forma:

$$\left(1 + \sigma + \frac{\rho_1}{2}\right) \hat{u}_{i,j}^{n+1/2} - \frac{\sigma}{2} \hat{u}_{i+1,j}^{n+1/2} - \left(\frac{\rho_1 + \sigma}{2}\right) \hat{u}_{i-1,j}^{n+1/2} = \left(1 - \sigma - \frac{\rho_2}{2}\right) u_{i,j}^n$$

$$+ \frac{\sigma}{2} u_{i,j+1}^n + \left(\frac{\sigma + \rho_2}{2}\right) u_{i,j-1}^n$$

$$\left(1 + \sigma + \frac{\rho_2}{2}\right) u_{i,j}^{n+1} - \frac{\sigma}{2} u_{i,j+1}^{n+1} - \left(\frac{\rho_2 + \sigma}{2}\right) u_{i,j-1}^{n+1} = \left(1 - \sigma - \frac{\rho_1}{2}\right) \hat{u}_{i,j}^{n+1/2} + \frac{\sigma}{2} \hat{u}_{i+1,j}^{n+1/2} + \left(\frac{\sigma + \rho_1}{2}\right) \hat{u}_{i-1,j}^{n+1/2}$$

onde

$$\sigma = \frac{\varepsilon \Delta t}{h^2}; \qquad \rho_1 = \frac{b_1 \Delta t}{h}; \qquad \rho_2 = \frac{b_2 \Delta t}{h}.$$

Método ADI – Esquema Central

Combinando a estratégia ADI com uma discretização upwind para o termo convectivo, obtemos:

$$\frac{\hat{u}_{i,j}^{n+1/2} - u_{i,j}^n}{\Delta t/2} = \varepsilon \left[\frac{\hat{u}_{i+1,j}^{n+1/2} - 2\hat{u}_{i,j}^{n+1/2} + \hat{u}_{i-1,j}^{n+1/2}}{\Delta x^2} + \frac{u_{i,j+1}^n - 2u_{i,j}^n + u_{i,j-1}^n}{\Delta y^2} \right] - \left[b_1 \frac{\hat{u}_{i+1,j}^{n+1/2} - \hat{u}_{i-1,j}^{n+1/2}}{2\Delta x} + b_2 \frac{u_{i,j+1}^n - u_{i,j-1}^n}{2\Delta y} \right]$$

$$\frac{u_{i,j}^{n+1} - \hat{u}_{i,j}^{n+1/2}}{\Delta t/2} = \varepsilon \left[\frac{\hat{u}_{i+1,j}^{n+1/2} - 2\hat{u}_{i,j}^{n+1/2} + \hat{u}_{i-1,j}^{n+1/2}}{\Delta x^2} + \frac{u_{i,j+1}^{n+1} - 2u_{i,j}^{n+1} + u_{i,j-1}^{n+1}}{\Delta y^2} \right] - \left[b1 \frac{\hat{u}_{i+1,j}^{n+1/2} - \hat{u}_{i-1,j}^{n+1/2}}{2\Delta x} + b_2 \frac{u_{i,j+1}^{n+1} - u_{i,j-1}^{n+1}}{2\Delta y} \right]$$

Método ADI – Esquema Central

Escolhendo $\Delta x = \Delta y = h$, podemos reescrever a discretização da seguinte forma:

$$\begin{split} (1+\sigma)\,\hat{u}_{i,j}^{n+1/2} + \left(\frac{\rho_1}{4} - \frac{\sigma}{2}\right)\hat{u}_{i+1,j}^{n+1/2} - \left(\frac{\rho_1}{4} + \frac{\sigma}{2}\right)\hat{u}_{i-1,j}^{n+1/2} = (1-\sigma)\,u_{i,j}^n \\ + \left(\frac{\sigma}{2} - \frac{\rho_2}{4}\right)u_{i,j+1}^n + \left(\frac{\sigma}{2} + \frac{\rho_2}{4}\right)u_{i,j-1}^n \end{split}$$

$$(1+\sigma) \, u_{i,j}^{n+1} + \left(\frac{\rho_2}{4} - \frac{\sigma}{2}\right) u_{i,j+1}^{n+1} - \left(\frac{\rho_2}{4} + \frac{\sigma}{2}\right) u_{i,j-1}^{n+1} = (1-\sigma) \, \hat{u}_{i,j}^{n+1/2} \\ + \left(\frac{\sigma}{2} - \frac{\rho_1}{4}\right) \hat{u}_{i+1,j}^{n+1/2} + \left(\frac{\sigma}{2} + \frac{\rho_1}{4}\right) \hat{u}_{i-1,j}^{n+1/2}$$

Resultados Numéricos

Encontrar $u(x,y,t)\in\Omega\times\Theta$ satisfazendo a seguinte equação:

$$\begin{split} \frac{\partial u}{\partial t} - \varepsilon \Delta u + \mathbf{b} \cdot \nabla u &= f(x,y,t) \quad \text{em} \quad \Omega \times \Theta \\ u(x,y,t) &= \overline{u} \qquad \text{sobre} \quad \partial \Omega \times \Theta \\ u(x,y,0) &= \varphi(x,y) \qquad \text{em} \quad \Omega \end{split}$$

Uma solução exata para este problema é dada por

$$u(x, y, t) = e^{-2\pi^2 t} \sin(\pi x) \sin(\pi y)$$

para esta solução no domínio $\Omega = [0,1] \times [0,1]$, temos $\overline{u} = 0$,

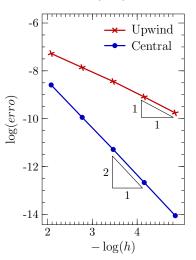
$$\varphi(x,y) = \sin(\pi x)\sin(\pi y)$$

е

$$f(x, y, t) = \pi e^{-2\pi^2 t} \left(b_1 \cos(\pi x) \sin(\pi y) + b_2 \sin(\pi x) \cos(\pi y) \right)$$

Estudo de Convergência

Para este estudo foi adotado $8\times 8, 16\times 16, 32\times 32, 64\times 64,$ 128×128 elementos, $\varepsilon=1,\ \mathbf{b}=(1,1)$ e $\Delta t=h.$



Custo Computacional

Supondo os dados:

- \triangleright malha de 64×64 elementos
- ightharpoonup n = 1000 iterações no tempo
- k número de equações do sistema

AS metodologias requerem a seguinte quantidade de operações

- ▶ Decomposição LU (complexidade $2k^3/3$)
 - $\frac{2}{3}k^3 = \frac{2}{3}3969^3 = 41.682.334.806 \text{ (a cada passo de tempo)}$ $\frac{2}{3}k^3n = \frac{2}{3}3969^31000 = 41.682.334.806.000 \text{ (total)}$
- ightharpoonup Algoritmo de Thomas (complexidade 8k)
 - 64 equações calculadas 64 vezes em cada direção (x e y)
 - \blacktriangleright 8 × 64 × 64 × 64 = 2.097.152 (a cada passo de tempo)
 - $8 \times 64 \times 64 \times 64 \times 1000 = 2.097.152.000$ (total)